

Evaluación causal del efecto de la Guardia Nacional sobre las desapariciones en México

Andrés Padrón Quintana

Manuel Alonso de la Tejera González

24 de May de 2026

Índice

1	Introducción	3
1.1	Pregunta de investigación	3
1.2	Hipótesis de trabajo	3
2	Datos	4
2.1	Unidad de análisis	4
2.2	Variable de tratamiento	5
2.3	Construcción esperada del panel	5
2.4	Preprocesamiento y limpieza de datos	6
2.5	Construcción del panel entidad–periodo	6
2.6	Análisis exploratorio de datos	7
3	Marco causal y diagrama causal	10
4	Diferencia en Diferencias (DID)	13
4.1	Modelo básico de Diferencia en Diferencias	13
4.2	Resultados del modelo DID básico	14
4.3	Resultados del modelo DID con efectos fijos	14
5	Estudio de eventos	16
6	Control Sintético	17
6.1	Supuestos de identificación del Control Sintético	20

7	Inferencia Causal Bayesiana con CausalImpact (BSTS)	20
7.1	Modelo estructural de espacio de estados	21
7.2	Supuestos de identificación de CausalImpact (BSTS)	21
7.3	Resultados	22
8	Comparación de métodos	23
9	Bibliografía	24
10	Anexos	24
10.1	Repositorio del proyecto	24

1 Introducción

Las desapariciones de personas en México constituyen uno de los problemas públicos más graves del país. Además de su dimensión humanitaria, jurídica y social, el fenómeno presenta una estructura temporal y territorial compleja: las desapariciones no ocurren de manera homogénea entre entidades federativas ni evolucionan de forma constante a través del tiempo. Por ello, su análisis requiere herramientas estadísticas capaces de incorporar tanto la dimensión temporal como la comparación entre regiones.

En este proyecto se propone evaluar el posible efecto causal asociado con la aparición e implementación de la Guardia Nacional sobre el comportamiento de las desapariciones en México. La Guardia Nacional fue planteada como una intervención de seguridad pública de alcance nacional; sin embargo, su presencia, intensidad operativa y efectos potenciales pueden variar entre entidades federativas. Esta variación permite estudiar si ciertos estados experimentaron cambios diferenciales en las desapariciones después de la intervención, en comparación con estados que funcionen como grupo de control.

El objetivo del estudio no es únicamente describir la evolución de las desapariciones, sino construir un marco causal que permita aproximar el contrafactual: qué habría ocurrido con las desapariciones en ciertas entidades si la intervención asociada con la Guardia Nacional no hubiera ocurrido o no hubiera tenido la misma intensidad. Para ello, se utilizarán dos metodologías principales de inferencia causal en contextos dinámicos: Diferencia en Diferencias, Study Events, Controles Sintéticos e Inferencia Causal Bayesiana con CausalImpact.

1.1 Pregunta de investigación

La pregunta principal del proyecto es:

¿Cuál fue el efecto causal asociado con la aparición e implementación de la Guardia Nacional sobre las desapariciones en México?

De forma más específica, se busca responder:

¿Las entidades con mayor exposición o intensidad de presencia de la Guardia Nacional presentaron un cambio diferencial en las desapariciones después de la intervención, en comparación con entidades similares con menor exposición?

1.2 Hipótesis de trabajo

La hipótesis general es que la implementación de la Guardia Nacional pudo modificar la dinámica de desapariciones en ciertas entidades federativas. Sin embargo, el signo esperado del efecto no es necesariamente evidente. Por un lado, una mayor presencia de seguridad pública podría estar asociada con una reducción en desapariciones si efectivamente inhibe la actividad criminal. Por otro lado, también podría observarse un aumento si la intervención se concentra en regiones con deterioro previo de seguridad, si genera desplazamiento de violencia, o si mejora los mecanismos de denuncia y registro.

Por esta razón, el análisis se plantea de forma empírica y causal, evitando asumir de antemano que el efecto debe ser positivo o negativo. El interés principal será estimar y discutir el cambio diferencial observado, bajo los supuestos de identificación de los métodos utilizados.

2 Datos

Para el análisis se consideran datos observados sobre desapariciones en México. La información utilizada proviene del Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO), base de datos oficial administrada por la Comisión Nacional de Búsqueda (CNB), la cual concentra y actualiza información sobre personas desaparecidas y no localizadas en el país.

Los datos empleados en este proyecto fueron obtenidos a partir de la Consulta Pública del RNPDNO. En particular, la recopilación, estructuración y organización inicial de los datos se realizó utilizando el repositorio público desarrollado por Montserrat, disponible en:

<https://github.com/lapanquecita/personas-desaparecidas>

Dicho repositorio contiene scripts para descargar, limpiar y analizar la información pública del RNPDNO, permitiendo construir bases de datos estructuradas para análisis estadístico y temporal.

La información disponible incluye variables relacionadas con fecha de desaparición, entidad federativa, municipio, sexo, edad, estatus y otras características relevantes asociadas a los registros de desaparición.

Para el presente estudio se utilizarán principalmente dos conjuntos de datos:

1. `data.csv`, que contiene registros individuales o más desagregados de desapariciones.
2. `timeseries_victimas.csv`, que contiene información agregada en formato de serie temporal, incluyendo variables como periodo, entidad federativa y número total de víctimas.

Dado el objetivo causal del proyecto, el archivo `timeseries_victimas.csv` será la principal fuente para la construcción del panel temporal entidad–periodo. El archivo `data.csv` podrá utilizarse como fuente complementaria para exploración descriptiva, validación de patrones generales y construcción de visualizaciones auxiliares.

2.1 Unidad de análisis

La unidad de análisis será:

$$(i, t) = (\text{entidad federativa}, \text{periodo})$$

donde i representa la entidad federativa y t representa el periodo temporal de observación. En principio, se trabajará con frecuencia mensual, siempre que la estructura final de la base lo permita.

La variable de resultado será el número de desapariciones registradas en la entidad i durante el periodo t , denotada por:

$$Y_{it}.$$

Dependiendo de la disponibilidad de información poblacional, se considerará utilizar tasas de desaparición por cada 100,000 habitantes con el objetivo de mejorar la comparabilidad entre entidades federativas con tamaños poblacionales distintos.

2.2 Variable de tratamiento

La variable de tratamiento buscará capturar la exposición de cada entidad federativa a la Guardia Nacional. Esta definición representa una de las principales decisiones metodológicas del proyecto, ya que la Guardia Nacional tuvo alcance nacional, pero con intensidad de despliegue potencialmente distinta entre entidades.

De manera preliminar, se consideran las siguientes posibilidades para operacionalizar el tratamiento:

1. Clasificar como tratadas aquellas entidades con alta presencia o despliegue de Guardia Nacional.
2. Construir una medida relativa de intensidad utilizando información sobre efectivos, cuarteles u operativos.
3. Identificar entidades prioritarias de intervención y compararlas con entidades de menor exposición.

En una primera aproximación se utilizará una definición binaria de tratamiento:

$$G_i = \begin{cases} 1, & \text{si la entidad } i \text{ pertenece al grupo tratado,} \\ 0, & \text{si la entidad } i \text{ pertenece al grupo de control.} \end{cases}$$

Asimismo, se definirá un periodo posterior a la intervención:

$$Post_t = \begin{cases} 1, & \text{si } t \text{ ocurre después de la implementación de la Guardia Nacional,} \\ 0, & \text{si } t \text{ ocurre antes de la implementación de la Guardia Nacional.} \end{cases}$$

La variable de tratamiento efectiva será:

$$D_{it} = G_i \times Post_t.$$

2.3 Construcción esperada del panel

El análisis se realizará sobre una estructura tipo panel con observaciones por entidad y periodo temporal. La construcción general del panel tendrá la siguiente forma conceptual:

(Entidad, Periodo, Desapariciones, Tratamiento)

La ventana temporal definitiva será seleccionada buscando contar con suficientes periodos pretratamiento y postratamiento, lo cual es particularmente importante para evaluar la plausibilidad del supuesto de tendencias paralelas en Diferencia en Diferencias y para construir adecuadamente el contrafactual en Control Sintético.

2.4 Preprocesamiento y limpieza de datos

Como primera etapa del proyecto, se realizó un proceso de limpieza y estandarización de las bases de datos obtenidas del RNPDO. Este procedimiento tuvo como objetivo generar conjuntos de datos consistentes y reproducibles para el análisis causal posterior.

Las principales actividades realizadas fueron las siguientes:

1. Carga de los archivos originales utilizando `readr`.
2. Estandarización de nombres de variables mediante la librería `janitor`.
3. Conversión y validación de variables temporales.
4. Revisión de valores faltantes y consistencia estructural de las bases.
5. Verificación de cobertura temporal y territorial de los registros.
6. Generación de versiones limpias y reproducibles de las bases de datos.

Después del proceso de limpieza, se obtuvieron dos conjuntos de datos principales:

- `data_clean.csv`, que contiene registros individuales de desapariciones.
- `timeseries_clean.csv`, que contiene información agregada en formato temporal y que será utilizada para la construcción del panel entidad–periodo.

La base agregada contiene información para las 32 entidades federativas de México y cubre observaciones desde 2015, lo cual permite contar con periodos pretratamiento y postratamiento adecuados para los métodos de inferencia causal considerados en el estudio.

2.5 Construcción del panel entidad–periodo

Una vez finalizado el proceso de limpieza y validación de las bases de datos, se procedió a construir el conjunto de datos principal para el análisis causal. Dado que el objetivo del proyecto consiste en estudiar cambios en desapariciones a través del tiempo y entre entidades federativas, se construyó una estructura tipo panel con observaciones por entidad y periodo temporal.

La unidad de análisis del estudio quedó definida como:

$$(i, t) = (\text{entidad federativa}, \text{periodo})$$

donde i representa la entidad federativa y t representa el periodo mensual de observación.

A partir de la base `timeseries_clean.csv`, se agregaron las observaciones por entidad y mes, obteniendo una medida mensual del número total de desapariciones registradas en cada estado. Formalmente, la variable de resultado utilizada en esta etapa se define como:

$$Y_{it} = \text{Número de desapariciones en la entidad } i \text{ durante el periodo } t.$$

Posteriormente, se construyó una variable temporal asociada con el periodo posterior a la implementación de la Guardia Nacional:

$$Post_t = \begin{cases} 1, & \text{si } t \geq \text{junio de 2019,} \\ 0, & \text{en otro caso.} \end{cases}$$

La fecha de junio de 2019 fue seleccionada debido a que corresponde al inicio formal de operaciones de la Guardia Nacional en México. Esta variable permitirá posteriormente identificar cambios diferenciales en las trayectorias temporales de desapariciones antes y después de la intervención.

El resultado final de esta etapa fue la construcción de un panel balanceado para las 32 entidades federativas del país. Cada entidad cuenta con 130 observaciones mensuales, lo cual implica que todas las unidades presentan la misma cobertura temporal dentro de la ventana de estudio.

La estructura balanceada del panel representa una ventaja importante para los métodos de inferencia causal considerados en este proyecto, particularmente para modelos de Diferencia en Diferencias y estudios de eventos, ya que facilita la comparación entre grupos tratados y de control a lo largo del tiempo y reduce problemas derivados de observaciones faltantes o periodos desalineados.

Asimismo, contar con una estructura temporal homogénea permitirá posteriormente analizar tendencias previas a la intervención, evaluar la plausibilidad del supuesto de tendencias paralelas y construir contrafactuales más consistentes mediante técnicas de control sintético.

2.6 Análisis exploratorio de datos

Como primera aproximación empírica, se realizó un análisis exploratorio de la serie temporal de desapariciones con el objetivo de identificar patrones generales, heterogeneidad entre entidades federativas y posibles cambios alrededor del periodo de implementación de la Guardia Nacional.

Este análisis todavía no tiene una interpretación causal directa, pero resulta fundamental para motivar el diseño empírico posterior. En particular, permite observar si existen tendencias temporales relevantes, qué entidades concentran una mayor proporción de registros y si algunas trayectorias estatales podrían ser candidatas para construir grupos de tratamiento y control.

2.6.1 Evolución nacional de desapariciones

La Figura 1 presenta la evolución mensual del número total de desapariciones registradas en México. La línea vertical punteada indica junio de 2019, periodo utilizado como referencia preliminar para la implementación de la Guardia Nacional.




Figura 1: Desapariciones en México a través del tiempo.

La serie nacional muestra una tendencia creciente a lo largo del periodo de estudio, acompañada de una volatilidad mensual considerable. Posterior a 2019 se observan niveles generalmente más altos que en los primeros años de la muestra. Sin embargo, esta comparación agregada debe interpretarse con cautela, ya que puede estar influida por cambios generales en el país, variaciones en los mecanismos de denuncia, diferencias estatales y eventos concurrentes no atribuibles directamente a la Guardia Nacional.

Por esta razón, el análisis causal no se basará únicamente en la serie nacional agregada, sino en una estructura tipo panel que permita comparar entidades federativas con distintas trayectorias y niveles de exposición a la intervención.

2.6.2 Entidades con mayor número acumulado de desapariciones

La Figura 2 muestra las diez entidades con mayor número acumulado de desapariciones durante el periodo analizado.




Figura 2: Diez entidades con mayor número acumulado de desapariciones.

El análisis acumulado muestra una fuerte heterogeneidad territorial. En particular, el Estado de México concentra el mayor número de desapariciones registradas en el periodo, con una diferencia considerable respecto al resto de las entidades. Le siguen Guanajuato, Baja California, Jalisco, Ciudad de México y Nuevo León, entre otras.

Esta heterogeneidad es relevante para el diseño causal porque sugiere que las entidades no son directamente comparables en niveles. Por ello, los métodos utilizados deberán apoyarse en comparaciones temporales, tendencias pretratamiento y construcción de contrafactuales, más que en comparaciones simples de niveles promedio.

2.6.3 Tendencias temporales en las principales entidades

La Figura 3 presenta las trayectorias mensuales de desapariciones para las cinco entidades con mayor número acumulado de registros.




Figura 3: Tendencias temporales de desapariciones en las cinco entidades con mayor número acumulado.

Las trayectorias estatales evidencian diferencias importantes tanto en niveles como en evolución temporal. El Estado de México presenta niveles considerablemente superiores al resto de las entidades, lo cual sugiere que puede comportarse como una unidad atípica dentro del análisis. Por otro lado, entidades como Guanajuato, Jalisco, Baja California y Ciudad de México presentan trayectorias más cercanas entre sí en ciertos periodos, aunque con diferencias relevantes en la etapa posterior a 2019.

Este resultado es importante para las siguientes etapas del proyecto. En primer lugar, sugiere que la selección del grupo tratado y del grupo de control debe realizarse con cuidado, evitando comparaciones entre entidades con dinámicas excesivamente distintas. En segundo lugar, la visualización de tendencias previas será fundamental para evaluar la plausibilidad del supuesto de tendencias paralelas requerido por el método de Diferencia en Diferencias. Finalmente, la presencia de entidades con trayectorias diferenciadas justifica el uso complementario de Control Sintético, especialmente para analizar casos específicos donde sea posible construir un contrafactual adecuado.

En conjunto, el análisis exploratorio muestra que el fenómeno de desapariciones en México presenta una dimensión temporal y territorial suficientemente rica para ser estudiada mediante métodos dinámicos de inferencia causal. La siguiente etapa consistirá en definir formalmente las entidades tratadas y de control, así como estimar los modelos causales propuestos.

3 Marco causal y diagrama causal

El objetivo causal del proyecto consiste en estimar el efecto de la implementación y presencia de la Guardia Nacional sobre el número de desapariciones registradas en México.

Formalmente, el tratamiento se define como:

$T = \text{Implementación / presencia de la Guardia Nacional}$

mientras que la variable de resultado corresponde al número de desapariciones registradas por entidad y periodo:

$Y_{it} = \text{Número de desapariciones en la entidad } i \text{ en el periodo } t$

donde:

- i representa la entidad federativa,
- t representa el periodo mensual de observación.

Bajo el marco de resultados potenciales, cada entidad federativa posee dos resultados potenciales:

$Y_i(1)$

correspondiente al número de desapariciones bajo tratamiento, y

$Y_i(0)$

correspondiente al resultado contrafactual en ausencia de tratamiento.

Sin embargo, para cada unidad únicamente observamos uno de estos dos resultados, lo cual motiva la necesidad de utilizar métodos de inferencia causal para aproximar el contrafactual.

La Figura 4 presenta el diagrama causal (DAG) propuesto para el proyecto.




Figura 4: Diagrama causal del proyecto.

El DAG resume las principales relaciones causales consideradas en el análisis. En particular, se identifican múltiples variables de confusión (*confounders*) que afectan tanto la implementación de la Guardia Nacional como el número de desapariciones observadas.

Entre las principales variables de confusión consideradas destacan:

- violencia previa,
- presencia de crimen organizado,
- capacidad institucional y policial estatal,
- factores socioeconómicos,
- tendencias regionales,
- y choques nacionales comunes.

Estas variables generan caminos de backdoor entre el tratamiento y el resultado:

$$T \leftarrow X \rightarrow Y$$

Asimismo, el DAG permite identificar posibles variables tipo collider. Por ejemplo, la mejora en capacidades de registro y denuncia puede estar influida simultáneamente por la presencia de la Guardia Nacional y por cambios en los niveles reales de violencia. Condicionar incorrectamente sobre este tipo de variables podría inducir sesgos adicionales en la estimación causal.

Finalmente, es importante señalar que la Guardia Nacional constituye una política implementada a nivel nacional, por lo que el análisis no identifica un “efecto puro” absoluto de la intervención, sino cambios diferenciales en entidades específicas —particularmente Guanajuato— respecto a contrafactuales contruidos a partir de otras entidades federativas.

4 Diferencia en Diferencias (DID)

4.1 Modelo básico de Diferencia en Diferencias

Como primera aproximación causal, se estimó un modelo básico de Diferencia en Diferencias (Difference-in-Differences, DID), utilizando a Guanajuato como grupo tratado y al resto de las entidades federativas como grupo de control.

La especificación estimada fue:

$$Y_{it} = \alpha + \beta_1 Treated_i + \beta_2 Post_t + \beta_3 (Treated_i \times Post_t) + \varepsilon_{it}$$

donde:

- Y_{it} representa el número de desapariciones en la entidad i y periodo t ,
- $Treated_i$ indica si la entidad pertenece al grupo tratado,
- $Post_t$ identifica el periodo posterior a junio de 2019,
- y el término de interacción captura el efecto diferencial posterior al tratamiento.

El parámetro de interés es:

$$\beta_3$$

el cual representa el efecto promedio del tratamiento sobre el grupo tratado bajo el supuesto de tendencias paralelas.

La Figura 5 presenta la evolución temporal del grupo tratado y el grupo de control.




Figura 5: Comparación de tendencias temporales entre Guanajuato y el grupo de control.

Visualmente, ambas series presentan una tendencia creciente antes de la implementación de la Guardia Nacional, aunque existen diferencias importantes en niveles. Esto sugiere que el supuesto de tendencias paralelas debe interpretarse con cautela y posteriormente validarse mediante especificaciones más robustas.

4.2 Resultados del modelo DID básico

El modelo básico DID produjo un coeficiente positivo y estadísticamente significativo para el término de interacción:

$$\hat{\beta}_3 \approx 543$$

lo que sugiere que, posterior a 2019, Guanajuato presentó aproximadamente 543 desapariciones adicionales por periodo respecto a la evolución observada en el grupo de control.

Sin embargo, esta especificación todavía no controla por heterogeneidad no observada entre entidades ni por shocks agregados comunes en el tiempo, por lo que sus resultados deben interpretarse únicamente como evidencia preliminar.

4.3 Resultados del modelo DID con efectos fijos

Para controlar por heterogeneidad inobservable constante en el tiempo y por shocks comunes a todas las entidades, se estimó un modelo DID con efectos fijos de entidad y periodo:

$$Y_{it} = \alpha_i + \delta_t + \beta(Treated_i \times Post_t) + \varepsilon_{it}$$

donde:

- α_i representa efectos fijos por entidad,
- δ_t representa efectos fijos temporales,
- y el coeficiente de interacción mide el efecto diferencial posterior al tratamiento.

El resultado principal fue:

$$\hat{\beta} \approx 542.6$$

con alta significancia estadística ($p < 0.001$).

Este resultado sugiere que, incluso después de controlar por diferencias estructurales entre entidades y variaciones comunes en el tiempo, Guanajuato experimentó un incremento diferencial en desapariciones posterior a la implementación de la Guardia Nacional.

No obstante, es importante enfatizar que este resultado no implica necesariamente causalidad definitiva, ya que la validez del DID depende críticamente del supuesto de tendencias paralelas y de la ausencia de shocks simultáneos específicos para Guanajuato. Por esta razón, en las siguientes etapas se explorarán metodologías complementarias, particularmente Event Study y Control Sintético, para evaluar la robustez de los resultados obtenidos.

4.3.1 Supuestos de identificación del DID

La interpretación causal del estimador DID depende de varios supuestos fundamentales.

1. Tendencias paralelas

En ausencia del tratamiento, el grupo tratado y el grupo de control habrían seguido trayectorias temporales paralelas en promedio. Formalmente:

$$E[Y_{it}(0) - Y_{is}(0) \mid Treated_i = 1] = E[Y_{it}(0) - Y_{is}(0) \mid Treated_i = 0].$$

Este es el supuesto central del método y no puede verificarse directamente para el periodo postratamiento. Sin embargo, puede evaluarse indirectamente mediante tendencias pretratamiento y estudios de eventos.

2. Ausencia de shocks simultáneos diferenciales

No deben existir eventos contemporáneos que afecten únicamente al grupo tratado en el periodo posterior a la intervención. De lo contrario, el efecto estimado podría capturar otros cambios distintos a la intervención de interés.

3. Composición estable de grupos

La composición del grupo tratado y del grupo de control debe permanecer relativamente estable a lo largo del tiempo. Cambios sistemáticos en registro, medición o definición de unidades podrían sesgar la estimación.

4. SUTVA (Stable Unit Treatment Value Assumption)

El tratamiento asignado a una entidad no debe afectar directamente los resultados potenciales de otras entidades. En este contexto, implicaría asumir que la implementación de la Guardia Nacional en un estado no altera las desapariciones en otros estados mediante desplazamiento de actividad criminal o spillovers espaciales.

En el presente proyecto, la evidencia gráfica del estudio de eventos sugiere que el supuesto de tendencias paralelas podría no cumplirse perfectamente para Guanajuato. Por ello, los resultados DID deben interpretarse con cautela y complementarse con metodologías adicionales.

5 Estudio de eventos

Para complementar el modelo de Diferencia en Diferencias, se estimó un estudio de eventos. Esta especificación permite analizar la evolución dinámica del efecto relativo antes y después de la fecha de intervención. En particular, el estudio de eventos es útil para evaluar si existían diferencias sistemáticas entre el grupo tratado y el grupo de control antes de la implementación de la Guardia Nacional.

La especificación general estimada fue:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \delta_k \mathbf{1}(t - T_0 = k) \cdot Treated_i + \varepsilon_{it},$$

donde k representa el tiempo relativo respecto a junio de 2019, T_0 es el periodo de referencia de la intervención, α_i son efectos fijos por entidad y λ_t son efectos fijos por periodo. El periodo $k = -1$ se omite como categoría de referencia.




Figura 6: Estudio de eventos para Guanajuato respecto al grupo de control.

La Figura 6 muestra la evolución de los coeficientes estimados en tiempo relativo al tratamiento. Los puntos representan los efectos estimados para cada periodo y las líneas verticales corresponden a los intervalos de confianza.

Los resultados muestran que el efecto estimado no aparece como un salto inmediato justo después de junio de 2019. En los periodos cercanos a la intervención, varios coeficientes se mantienen cerca de cero y no presentan evidencia estadística clara de un cambio abrupto. Sin embargo, en los periodos posteriores más alejados se observa una tendencia creciente en los coeficientes estimados, lo cual sugiere que la diferencia entre Guanajuato y el grupo de control se amplía gradualmente después de la intervención.

No obstante, también se observan coeficientes negativos y estadísticamente significativos en algunos periodos previos al tratamiento, especialmente en meses lejanos al periodo de referencia. Esto indica que Guanajuato no necesariamente seguía una trayectoria completamente paralela a la del grupo de control durante todo el periodo pretratamiento. Por esta razón, los resultados del modelo DID deben interpretarse con cautela.

En conjunto, el estudio de eventos sugiere que la evidencia es consistente con una divergencia posterior entre Guanajuato y el grupo de control, pero también muestra limitaciones importantes en la validez del supuesto de tendencias paralelas. Por ello, el análisis se complementará con el método de Control Sintético, que permite construir un contrafactual específico para Guanajuato a partir de una combinación ponderada de entidades donadoras.

6 Control Sintético

Como complemento al análisis de Diferencia en Diferencias y al estudio de eventos, se estimó un modelo de Control Sintético para Guanajuato. Este método permite construir una unidad contrafactual a partir de una combinación ponderada de entidades federativas no tratadas. La idea central es generar un “Guanajuato sintético” cuya trayectoria previa a junio de 2019 sea lo más parecida posible a la trayectoria observada de Guanajuato.

Formalmente, el control sintético se construye como:

$$Y_t^{SC} = \sum_{j=1}^J w_j Y_{jt},$$

donde Y_t^{SC} representa el resultado del control sintético en el periodo t , Y_{jt} es el resultado observado en la entidad donadora j , y w_j son pesos no negativos que satisfacen:

$$w_j \geq 0, \quad \sum_{j=1}^J w_j = 1.$$

Los pesos se eligen de manera que la combinación ponderada de entidades donadoras reproduzca lo mejor posible la trayectoria pretratamiento de Guanajuato. Después de junio de 2019, la diferencia entre Guanajuato observado y Guanajuato sintético se interpreta como una aproximación del efecto diferencial posterior a la intervención.




Figura 7: Trayectoria observada de Guanajuato y trayectoria contrafactual estimada mediante Control Sintético.

La Figura 7 muestra la comparación entre la trayectoria observada de Guanajuato y su contraparte sintética. Antes de junio de 2019, ambas series presentan una evolución relativamente cercana, aunque el ajuste no es perfecto. Esto indica que el procedimiento logra aproximar de manera razonable la dinámica previa de Guanajuato utilizando una combinación ponderada de otras entidades federativas.

Después del periodo de intervención, se observa una separación creciente entre ambas trayectorias. La serie observada de Guanajuato se mantiene de forma persistente por encima de la trayectoria sintética, lo que sugiere que las desapariciones observadas en Guanajuato fueron mayores que las que se habrían esperado bajo el contrafactual construido por el modelo.




Figura 8: Brecha entre Guanajuato observado y Guanajuato sintético.

La Figura 8 presenta la brecha entre Guanajuato observado y Guanajuato sintético, definida como:

$$\hat{\tau}_t = Y_{Guanajuato,t}^{obs} - Y_{Guanajuato,t}^{SC}$$

Una brecha cercana a cero indica que el control sintético reproduce adecuadamente la trayectoria observada. Una brecha positiva indica que Guanajuato registró más desapariciones que su contrafactual sintético, mientras que una brecha negativa indicaría lo contrario.

Durante el periodo previo a la intervención, la brecha fluctúa alrededor de niveles relativamente moderados, lo cual sugiere un ajuste pretratamiento razonable. En cambio, después de junio de 2019, la brecha se vuelve persistentemente positiva y aumenta gradualmente. Este patrón es consistente con una divergencia posterior entre Guanajuato y su contrafactual sintético.

Los pesos estimados para construir el control sintético muestran que el algoritmo no dependió de una sola entidad federativa, sino de una combinación de varias entidades donadoras. En particular, Michoacán de Ocampo recibió el mayor peso individual dentro de la combinación sintética, mientras que el resto del peso se distribuyó entre múltiples entidades con aportaciones menores. Esto sugiere que Guanajuato presenta una dinámica difícil de replicar con una sola entidad de comparación, por lo que el modelo utiliza una combinación amplia de trayectorias estatales para aproximar su comportamiento previo.

En conjunto, los resultados del Control Sintético refuerzan la evidencia observada en el análisis de Diferencia en Diferencias y en el estudio de eventos: después de junio de 2019, Guanajuato presenta una trayectoria de desapariciones superior a la estimada por su contrafactual. No obstante, la interpretación causal debe mantenerse con cautela, ya que el diseño depende de que el control sintético capture adecuadamente la evolución que habría seguido Guanajuato en ausencia de la intervención y de que no existan shocks simultáneos específicos para la entidad.

6.1 Supuestos de identificación del Control Sintético

La validez causal del método de Control Sintético depende de varios supuestos importantes.

1. Buen ajuste pretratamiento

La combinación ponderada de unidades donadoras debe reproducir adecuadamente la trayectoria observada de la unidad tratada antes de la intervención. Un mal ajuste pretratamiento debilita la credibilidad del contrafactual estimado.

2. Ausencia de shocks idiosincráticos simultáneos

Después de la intervención, no deben existir eventos específicos que afecten únicamente a la unidad tratada y que no estén relacionados con el tratamiento.

3. Convexidad del contrafactual

Se asume que la trayectoria contrafactual de la unidad tratada puede aproximarse mediante una combinación convexa de unidades donadoras:

$$w_j \geq 0, \quad \sum_{j=1}^J w_j = 1.$$

4. Estabilidad estructural

La relación entre la unidad tratada y las unidades donadoras observada en el periodo pretratamiento debe mantenerse estable en ausencia de intervención durante el periodo postratamiento.

En este proyecto, el ajuste pretratamiento obtenido para Guanajuato fue razonablemente cercano, aunque no perfecto. Por ello, el Control Sintético debe interpretarse como una aproximación empírica del contrafactual y no como una reconstrucción exacta de la trayectoria no observada.

7 Inferencia Causal Bayesiana con CausalImpact (BSTS)

Como método adicional de validación, se implementó el enfoque de CausalImpact propuesto por Brodersen, Gallusser, Koehler, Remy y Scott (2015) en *The Annals of Applied Statistics*. El método parte de un problema central para toda la inferencia causal observacional: en ausencia de un experimento aleatorizado, ¿cómo construir de forma creíble el contrafactual de una unidad expuesta a una intervención? La propuesta de Brodersen et al. consiste en modelar la serie de tiempo de la unidad tratada durante el periodo previo a la intervención utilizando como covariables las series de tiempo de unidades no tratadas que estén correlacionadas con ella. Una vez ajustado el modelo sobre el pretratamiento, se proyecta hacia el postratamiento para obtener la trayectoria esperada en ausencia de intervención. La diferencia entre lo observado y esa proyección constituye el efecto causal estimado.

La principal innovación respecto a los métodos de Diferencia en Diferencias y Control Sintético es que este contrafactual no se resume en un valor puntual, sino en una distribución posterior completa, lo que permite cuantificar la incertidumbre de la estimación mediante intervalos de credibilidad bayesianos periodo a periodo.

7.1 Modelo estructural de espacio de estados

El mecanismo subyacente de CausalImpact es un modelo estructural de series de tiempo bayesiano (BSTS, por sus siglas en inglés), que descompone la serie observada en componentes con interpretación estadística propia. En su formulación general de espacio de estados, el modelo tiene la forma:

$$Y_t = \mathbf{Z}_t^\top \alpha_t + \mathbf{x}_t^\top \beta + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2),$$

$$\alpha_{t+1} = \mathbf{T}_t \alpha_t + \mathbf{R}_t \eta_t, \quad \eta_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_t),$$

donde α_t es el vector de estado latente no observado, $\mathbf{Z}_t$, $\mathbf{T}_t$ y $\mathbf{R}_t$ son matrices de diseño que definen la estructura del modelo, $\mathbf{x}_t$ es el vector de covariables de control y β son sus coeficientes de regresión. La ecuación de observación vincula los datos con el estado latente; la ecuación de transición describe cómo evoluciona dicho estado en el tiempo.

En la implementación utilizada en este proyecto, el componente de estado incluye una tendencia local de nivel (*local level*), que permite que el nivel medio de la serie varíe suavemente a lo largo del tiempo sin imponer una forma funcional rígida:

$$\mu_t = \mu_{t-1} + \nu_t, \quad \nu_t \sim \mathcal{N}(0, \sigma_\mu^2).$$

7.2 Supuestos de identificación de CausalImpact (BSTS)

La interpretación causal del modelo BSTS implementado mediante CausalImpact depende de los siguientes supuestos.

1. Covariables no afectadas por el tratamiento

Las series utilizadas como covariables de control no deben verse afectadas por la intervención. Si las covariables también responden al tratamiento, el contrafactual estimado puede contaminarse.

2. Relación estable pre-post

La relación estadística entre la unidad tratada y las covariables observada en el periodo pretratamiento debe mantenerse estable en ausencia de intervención durante el periodo postratamiento.

3. Correcta especificación dinámica

El modelo estructural de espacio de estados debe capturar adecuadamente la dinámica temporal de la serie, incluyendo tendencia, persistencia y variabilidad temporal.

4. Ausencia de shocks simultáneos no modelados

No deben existir cambios estructurales adicionales posteriores a la intervención que afecten la serie tratada y que no estén representados mediante el componente estructural o las covariables del modelo.

Una ventaja importante de CausalImpact respecto a DID es que no requiere asumir tendencias paralelas globales entre unidades. En cambio, el método depende de la capacidad predictiva del modelo BSTS sobre el periodo pretratamiento.

7.3 Resultados

La Figura 9 muestra la serie observada de Guanajuato junto con el contrafactual estimado por el BSTS y su intervalo de credibilidad al 95%.




Figura 9: Serie observada de Guanajuato y contrafactual estimado por CausalImpact (BSTS). La banda sombreada corresponde al intervalo de credibilidad al 95%.

Durante el periodo pretratamiento, el contrafactual BSTS sigue de cerca la trayectoria observada de Guanajuato, lo que indica un ajuste adecuado del modelo sobre la dinámica previa de la entidad. A partir de junio de 2019, la serie observada se separa persistentemente por encima del contrafactual estimado, de forma consistente con los resultados del Control Sintético y del estudio de eventos.

La Figura 10 presenta el efecto causal puntual $\hat{\tau}_t$ estimado en cada periodo del postratamiento.




Figura 10: Efecto causal puntual estimado por CausalImpact. La banda sombreada es el intervalo de credibilidad al 95%. Valores positivos indican más desapariciones que el contrafactual esperado.

En términos cuantitativos, el modelo estima que, en ausencia de la intervención, Guanajuato habría registrado en promedio 1745.5 desapariciones mensuales, frente a las 2119.8 observadas. Esto se traduce en un efecto absoluto promedio de 374.2 desapariciones adicionales por mes (IC 95%: [194.4, 966]), equivalente a un incremento relativo de 23.5% respecto al contrafactual (IC 95%: [10.1%, 83.7%]). El p-valor bayesiano obtenido fue de 4×10^{-4} , lo que indica que la probabilidad de observar un efecto de esta magnitud por variación aleatoria es muy baja.

8 Comparación de métodos

Los cuatro enfoques aplicados en este proyecto responden la misma pregunta causal desde mecanismos de identificación distintos. La Tabla 1 resume los efectos estimados y los supuestos clave de cada método.

Cuadro 1: Comparación de métodos causales aplicados al análisis de Guanajuato.

Método	Efecto.estimado	Supuesto.clave
DID básico	+543 desapariciones/periodo	Tendencias paralelas globales
DID con efectos fijos	+542.6 desapariciones/periodo ($p < 0.001$)	Tendencias paralelas y ausencia de shocks específicos
Control Sintético	Brecha positiva creciente post-2019	Contrafactual como combinación convexa de entidades donadoras
CausalImpact (BSTS)	+374.2 desapariciones/mes (IC: [194.4, 966])	Covariables no afectadas por el tratamiento

La convergencia de los cuatro métodos hacia el mismo signo e interpretación constituye evidencia robusta de que Guanajuato experimentó un incremento diferencial en desapariciones posterior a junio de 2019. Esta convergencia es particularmente relevante dado que el estudio de eventos mostró limitaciones en el supuesto de tendencias paralelas, lo que debilita al DID como argumento aislado. El hecho de que el Control Sintético y CausalImpact, que operan bajo supuestos distintos y no requieren tendencias paralelas globales, lleguen a la misma conclusión refuerza la interpretación causal del resultado.

No obstante, ningún método elimina por completo la posibilidad de que factores no observados específicos de Guanajuato expliquen el incremento observado. Esta limitación es inherente a todo

diseño observacional y se discute con mayor detalle en las conclusiones del proyecto.

9 Bibliografía

1. Brodersen, Kay H., Fabian Gallusser, Jim Koehler, Nicolas Remy y Steven L. Scott (2015). “Inferring causal impact using Bayesian structural time-series models.” *The Annals of Applied Statistics*, 9(1), 247–274.
2. Ding, Peng (2024). *A First Course in Causal Inference*. CRC Press.
3. Gelman, Andrew y Jennifer Hill (2006). *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Cambridge University Press.
4. Hernán, Miguel A. y James Robins (2020). *Causal Inference: What If*. CRC Press.
5. Huntington-Klein, Nick (2022). *The Effect: An Introduction to Research Design and Causality*. CRC Press.
6. McElreath, Richard (2020). *Statistical Rethinking: A Bayesian Course with Examples in R and Stan*. 2nd Edition. CRC Press.
7. Pearl, Judea, Madelyn Glymour y Nicholas P. Jewell (2016). *Causal Inference in Statistics: A Primer*. Wiley.
8. Rosenbaum, Paul R. (2023). *Causal Inference*. The MIT Press.
9. Rubin, Donald B. (2006). *Matched Sampling for Causal Effects*. Cambridge University Press.
10. Callaway, Brantly y Pedro H. C. Sant’Anna (2021). “Difference-in-Differences with Multiple Time Periods.” *Journal of Econometrics*, 225(2), 200–230.
11. Sun, Liyang y Sarah Abraham (2021). “Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects.” *Journal of Econometrics*, 225(2), 175–199.
12. Comisión Nacional de Búsqueda (CNB). Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDO). Gobierno de México.
13. Montserrat Medina. Repositorio `personas-desaparecidas`. Disponible en:

<https://github.com/lapanquecita/personas-desaparecidas>
14. De la Vega Góngora, Jorge. *Notas del curso Métodos Analíticos*. Maestría en Ciencia de Datos, ITAM, 2026.

10 Anexos

10.1 Repositorio del proyecto

El código completo utilizado para la limpieza de datos, construcción del panel, análisis exploratorio, estimación de modelos causales y generación del reporte se encuentra disponible en el siguiente repositorio público de GitHub:

<https://github.com/andres-padronqu/dynamic-causal-inference>